

TUGAS AKHIR EKONOMETRI (B)
ANALISIS DATA DAN PREDIKSI HARGA PENUTUPAN SAHAM PT TELKOM
INDONESIA (PERSERO) TBK MENGGUNAKAN MODEL ARIMA-GARCH



Dosen Pengampu:
Mila Novita, S.Si., M.Si.

Disusun oleh:
Kelompok 14

Shinta Chandra 2206053940

Vanny Khairunnisaa 2206051506

DEPARTEMEN MATEMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS INDONESIA

2024

ABSTRAK

Penelitian ini berfokus pada volatilitas harga penutupan saham bulanan PT Telkom Indonesia (Persero) Tbk (TLKM) dari Januari 2014 hingga Desember 2024 sebagai indikator penting dalam pengambilan keputusan investasi. Penelitian ini bertujuan memprediksi volatilitas harga saham menggunakan model *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH), yang mampu menangkap pola volatilitas bersyarat dalam data keuangan. Analisis dimulai dengan uji stasioneritas menggunakan *Augmented Dickey-Fuller* (ADF) dan diferensiasi untuk menjadikan data stasioner, menghasilkan model ARIMA (0,1,0) yang memenuhi asumsi pola *mean* acak, distribusi normal, dan efek ARCH. Hipotesis utama penelitian adalah model GARCH (1,1) dengan distribusi t-Student dapat secara signifikan menangkap volatilitas bersyarat dalam data harga saham TLKM. Hasil penelitian menunjukkan bahwa model ini mampu memprediksi volatilitas jangka panjang dengan baik meski kurang sensitif terhadap perubahan mendadak. Penelitian ini memberikan wawasan praktis bagi investor dalam memahami dinamika volatilitas saham TLKM dan membuka peluang untuk pengembangan model prediksi yang lebih kompleks di masa depan.

Kata kunci: Volatilitas saham, GARCH, ARIMA, distribusi t-Student, prediksi harga saham.

PENDAHULUAN

Harga saham merupakan salah satu indikator penting dalam dunia keuangan yang mencerminkan kondisi pasar dan performa perusahaan. PT Telkom Indonesia (Persero) Tbk, sebagai salah satu perusahaan telekomunikasi terbesar di Indonesia, menjadi perhatian utama bagi investor domestik maupun internasional. Perubahan harga saham perusahaan ini dipengaruhi oleh berbagai faktor, termasuk sentimen pasar, kebijakan ekonomi, dan fluktuasi makroekonomi. Dalam kondisi pasar yang dinamis, prediksi harga saham menjadi tantangan sekaligus kebutuhan untuk mendukung pengambilan keputusan yang lebih baik.

Penelitian ini bertujuan untuk mengaplikasikan model *Generalized Autoregressive Conditional Heteroskedasticity* (GARCH) dalam memprediksi harga penutupan saham Telkom Indonesia. Model GARCH dipilih karena kemampuannya menangkap volatilitas yang sering muncul dalam data keuangan. Dengan menggunakan data historis, model ini dapat membantu mengidentifikasi pola volatilitas yang mungkin tidak terdeteksi oleh pendekatan linear. Uji asumsi dalam model GARCH juga dilakukan untuk memastikan keakuratan hasil prediksi yang diperoleh.

Kontribusi dari penelitian ini adalah memberikan pendekatan sistematis untuk memodelkan volatilitas saham Telkom Indonesia menggunakan model GARCH, yang diharapkan dapat memberikan manfaat praktis bagi investor dan analis keuangan. Selain itu, penelitian ini juga memberikan wawasan metodologis mengenai pentingnya uji asumsi dalam memastikan validitas model ekonometrik, khususnya dalam analisis data keuangan.

Berikut adalah rumusan pertanyaan penelitian:

1. Bagaimana pola volatilitas harga penutupan saham Telkom Indonesia berdasarkan data historis?
2. Sejauh mana model GARCH mampu memprediksi harga penutupan saham Telkom Indonesia secara akurat?
3. Apakah model GARCH memenuhi uji asumsi yang diperlukan untuk analisis data keuangan?
4. Apa implikasi dari hasil prediksi model GARCH terhadap pengambilan keputusan investasi?

STRATEGI IDENTIFIKASI

Data Sourcing


Data yang kami gunakan adalah data harga (rupiah) penutupan saham PT Telkom Indonesia (Persero) Tbk (TLKM) dari Januari 2014 hingga Desember 2024 yang direkam per bulan. Data yang digunakan merupakan data bulanan berjumlah 132 observasi yang sudah bersih dari *missing values* dan duplikasi. Data tersebut kami peroleh dari situs *investing.com*. Berikut ini adalah cuplikan *raw data* untuk 10 baris pertama:

Tanggal	Terakhir	Pembukaan	Tertinggi	Terendah	Vol.	Perubahan%
01/12/2024	2650	2720	2880	2500	1,58B	-0,0221
01/11/2024	2710	2820	2850	2500	2,71B	-0,039
01/10/2024	2820	2990	3130	2820	2,09B	-0,0569
01/09/2024	2990	3090	3190	2990	2,21B	-0,0229
01/08/2024	3060	2890	3080	2760	2,23B	0,0625
01/07/2024	2880	3130	3280	2840	2,73B	-0,0799
01/06/2024	3130	2930	3140	2700	2,14B	0,0793
01/05/2024	2900	3170	3200	2720	3,13B	-0,0852
01/04/2024	3170	3480	3520	2960	4,16B	-0,0865

Keterangan kolom:


1. Tanggal : Tanggal ketika data harga saham tersebut dicatat.
 2. Terakhir : Harga penutupan saham pada bulan tersebut. Ini adalah harga terakhir yang tercatat sebelum pasar ditutup.
 3. Tertinggi : Harga tertinggi yang dicapai saham sepanjang bulan perdagangan.
 4. Terendah : Harga terendah yang dicapai saham sepanjang bulan perdagangan.
 5. Vol : *Volume* perdagangan, yang menunjukkan jumlah saham yang diperdagangkan pada bulan itu.
 6. Perubahan %: Persentase perubahan harga saham dibandingkan dengan hari sebelumnya.
- Tanda "+" menunjukkan kenaikan harga, sedangkan tanda "-" menunjukkan penurunan harga.

Gambar 1. Grafik Harga Penutupan




Note: Pada gambar ini, hasil uji stasioner Augmented Dicky Fuller Test memiliki p-value 0.638 atau data tidak stasioner

Gambar 2. Grafik Harga *Differencing*




Note: Setelah differensiasi ini, data udah stasioner diuji menggunakan ADF Test dengan p-value 0.01.

Gambar 3. Plot ACF pada data difference 1 kali




Note: ACF menggunakan data yang di differensiasi 1 kali

Gambar 4. Plot PACF pada data difference 1 kali




Note: PACF menggunakan data yang di differensiasi 1 kali

Gambar 5. Plot ACF data difference kuadrat



Note: ACF pada data kuadrat yang di differensiasi 1 kali

Gambar 6. Plot PACF data difference kuadrat



Note: PACF pada data kuadrat yang di differensiasi 1 kali

Gambar 7. Hasil Auto ARIMA pada data

```
> model_arima <- auto.arima(dfs)
> summary(model_arima)
Series: dfs
ARIMA(0,1,0)

sigma^2 = 0.04606: log likelihood = 15.72
AIC=-29.44 AICc=-29.4 BIC=-26.56

Training set error measures:
              ME      RMSE      MAE      MPE      MAPE      MASE      ACF1
Training set 0.002858144 0.2137983 0.174146 -0.07047201 4.972715 0.2755838 -0.002376704
```

Gambar 8. Hasil Uji ADF pada data

```
Augmented Dickey-Fuller Test

data: df$Terakhir
Dickey-Fuller = -1.8516, Lag order = 5, p-value = 0.6382
alternative hypothesis: stationary
```

Note: Hipotesis null data stasioner

Gambar 9. Hasil Uji ADF pada diferensiasi 1

```
Augmented Dickey-Fuller Test

data: d1
Dickey-Fuller = -4.5084, Lag order = 5, p-value = 0.01
alternative hypothesis: stationary
```

Note: Hipotesis null data stasioner

Gambar 10. Hasil Uji Ljung Box ARIMA(0,1,0)

```
Ljung-Box test

data: Residuals from ARIMA(0,1,0)
Q* = 8.4079, df = 24, p-value = 0.9986

Model df: 0. Total lags used: 24
```

Note: Hipotesis null residual bersifat acak (*white noise*)

Gambar 11. Hasil Uji JB ARIMA (0,1,0)

```
Jarque Bera Test

data: residuals(model_arima)
X-squared = 2.8168, df = 2, p-value = 0.2445
```

Note: Hipotesis null residual berdistribusi normal

Gambar 12. Hasil Uji Arch Test ARIMA (0,1,0)

```
ARCH LM-test; Null hypothesis: no ARCH effects  
data: r1  
Chi-squared = 23.021, df = 12, p-value = 0.02755
```

Note: Hipotesis null tidak ada efek ARCH

Sebelum melakukan permodelan, akan dicek apakah data stasioner pada level atau memiliki unit *root* menggunakan uji *Augmented Dickey-Fuller*. Di bawah H_0 benar data tidak stasioner pada level atau memiliki unit root. Didapatkan data tidak stasioner dengan p-value $0.6382 > 0.05$ pada Gambar 8, maka perlu dilakukan diferensiasi. Pada data yang sudah dilakukan diferensial sebanyak satu kali melalui Gambar 9 terlihat p-value $(0.01) < 0.05$ sehingga terdapat cukup bukti untuk menolak H_0 . Grafik pada data setelah dan sebelum dilakukan diferensial dapat dilihat secara berturut-turut pada Gambar 1 dan Gambar 2. Data yang telah dilakukan diferensiasi satu kali dengan asumsi stasioner sudah terpenuhi, kemudian akan dibentuk model ARIMA berdasarkan grafik ACF dan PACF pada data diferensial satu kali.

Berdasarkan Gambar 3 dan Gambar 4 terlihat autokorelasi tidak signifikan di semua *lag*, sehingga aspek *mean* dalam data dianggap acak (*white noise*) sehingga model ARMA tidak diperlukan untuk menangkap pola pada *mean*. Untuk memperkuat pernyataan tersebut, akan dilakukan permodelan ARIMA pada data asli yang belum stasioner dengan fungsi `auto.arima` di R yang dapat dilihat pada Gambar 7. Didapatkan model terbaik ARIMA(0,1,0) yang berarti pola *mean* dari data d_1 sudah acak (karena order MA = 0 dan order AR = 0) dan data akan stasioner setelah di *differencing* satu kali. Selanjutnya, dilakukan *plotting* ACF dan PACF pada kuadrat data diferensiasi satu kali yang dapat dilihat pada Gambar 5 dan Gambar 6. Dari gambar tersebut didapatkan bahwa autokorelasi signifikan di beberapa *lag* yang mengindikasikan volatilitas tidak acak atau volatilitas data bersifat bersyarat. Dengan pendekatan seperti GARCH kita dapat menangkap pola volatilitas bersyarat tersebut, sehingga akan dilanjutkan pengujian beberapa asumsi pada model ARIMA(0,1,0) untuk mengetahui apakah memiliki efek ARCH di dalamnya sehingga dapat dilakukan permodelan GARCH(1,1)

Bentuk Umum ARIMA (p,1,q)

$$W_t = \phi_1 W_{t-1} + \phi_2 W_{t-2} + \dots + \phi_p W_{t-p} + e_t - \theta_1 e_{t-1} - \theta_2 e_{t-2} - \dots - \theta_q e_{t-q}$$

$$Y_t - Y_{t-1} = \phi_1 (Y_{t-1} - Y_{t-2}) + \dots + \phi_p (Y_{t-p} - Y_{t-p-1}) + e_t - \theta_1 e_{t-1} - \dots - \theta_q e_{t-q}$$

Bentuk Umum ARIMA (0,1,0)

$$Y_t = Y_{t-1} + e_t$$

Dengan model ARIMA (0,1,0) yang didapatkan melalui langkah sebelumnya akan dilakukan uji residual acak (*white noise*) menggunakan Ljung-Box, uji distribusi residual normal menggunakan Jarque Bera Test, serta uji efek ARCH pada residual kuadrat model dengan ARCH LM. Berdasarkan hasil uji tersebut yang dapat dilihat melalui Gambar 10 dan Gambar 11 didapatkan hasil bahwa residual dari model ARIMA (0,1,0) bersifat *white noise* dan berdistribusi normal sehingga model sudah cukup baik. Melalui Gambar 12 yang menunjukkan hasil dari uji ARCH LM didapatkan bahwa residual kuadrat model ARIMA(0,1,0) mengandung efek ARCH.

Untuk ARIMA (0,1,0) yang sudah memenuhi asumsi *white noise*, distribusi normal, dan adanya efek ARCH dapat dimodelkan menggunakan model GARCH (1,1) yaitu model GARCH dengan order p dan q paling sederhana. Pemodelan GARCH (1,1) ini juga didukung berdasarkan Fu, Mohsin, Zia your Rehman & Baig (2018) yang melakukan analisis empiris yang memodelkan volatilitas pasar saham Pakistan dengan mempertimbangkan lima teknik distribusi yang berbeda, termasuk Distribusi Normal (Norm), Distribusi t Student (Std.), Distribusi Kesalahan Umum (GED), Distribusi t Student dengan derajat kebebasan tetap (Std. dengan DOF tetap), dan Distribusi Kesalahan Umum dengan parameter tertentu (GED dengan parameter yang ditetapkan). Hasilnya menunjukkan bahwa GARCH (1, 1) dengan varians kondisional tertinggal dan gangguan kuadrat signifikan dalam semua distribusi. Maka dari itu, pada penelitian ini dilakukan perbandingan hasil GARCH (1,1) dengan distribusi normal dan distribusi t-Student.

Bentuk Umum GARCH(p,q)

$$\sigma_{t|t-1}^2 = \omega + \beta_1 \sigma_{t-1|t-2}^2 + \dots + \beta_p \sigma_{t-p|t-p-1}^2 + \alpha_1 r_{t-1}^2 + \dots + \alpha_q r_{t-q}^2$$

Bentuk Umum GARCH(1,1)

$$\sigma_{t|t-1}^2 = \omega + \beta_1 \sigma_{t-1|t-2}^2 + \alpha_1 r_{t-1}^2$$

Gambar 13. Performa GARCH (1,1) Distribusi Normal

-----					Weighted Ljung-Box Test on Standardized Residuals				
* GARCH Model Fit *					-----				
-----					statistic p-value				
Conditional Variance Dynamics					Lag[1]	5.269	0.02171		
-----					Lag[2*(p+q)+(p+q)-1][2]	5.401	0.03178		
GARCH Model : sGARCH(1,1)					Lag[4*(p+q)+(p+q)-1][5]	6.118	0.08435		
Mean Model : ARFIMA(0,0,0)					d.o.f=0				
Distribution : norm					H0 : No serial correlation				
Optimal Parameters					Weighted Ljung-Box Test on Standardized Squared Residuals				
-----					-----				
	Estimate	Std. Error	t value	Pr(> t)	statistic p-value				
mu	0.070774	0.010103	7.0054	0.000000	Lag[1]	0.2244	0.6357		
omega	0.005219	0.001405	3.7140	0.000204	Lag[2*(p+q)+(p+q)-1][5]	1.3459	0.7777		
alpha1	0.428316	0.219342	1.9527	0.050852	Lag[4*(p+q)+(p+q)-1][9]	2.4571	0.8440		
beta1	0.283628	0.139946	2.0267	0.042693	d.o.f=2				
Robust Standard Errors:					Weighted ARCH LM Tests				
-----					-----				
	Estimate	Std. Error	t value	Pr(> t)	Statistic Shape Scale P-Value				
mu	0.070774	0.014134	5.0072	0.000001	ARCH Lag[3]	0.396	0.500	2.000	0.5292
omega	0.005219	0.001758	2.9691	0.002987	ARCH Lag[5]	1.392	1.440	1.667	0.6211
alpha1	0.428316	0.245191	1.7469	0.080661	ARCH Lag[7]	1.949	2.315	1.543	0.7281
beta1	0.283628	0.160021	1.7724	0.076321	Nyblom stability test				
LogLikelihood : 92.97642					-----				
Information Criteria					Joint Statistic: 0.3564				
-----					Individual Statistics:				
Akaike	-1.4707				mu	0.09552			
Bayes	-1.3783				omega	0.06599			
Shibata	-1.4728				alpha1	0.13170			
Hannan-Quinn	-1.4331				beta1	0.08135			
					Asymptotic Critical Values (10% 5% 1%)				
					Joint Statistic: 1.07 1.24 1.6				
					Individual Statistic: 0.35 0.47 0.75				

Sign Bias Test			

	t-value	prob	sig
Sign Bias	1.7344	0.0855	*
Negative Sign Bias	0.9502	0.3440	
Positive Sign Bias	1.1178	0.2660	
Joint Effect	3.2531	0.3542	
Adjusted Pearson Goodness-of-Fit Test:			

group	statistic	p-value(g-1)	
1	20	124.1	1.871e-17
2	30	142.1	7.469e-17
3	40	176.9	1.847e-19
4	50	199.2	5.131e-20
Elapsed time : 0.05930495			

Gambar 14. Performa GARCH (1,1) Distribusi t-student

* GARCH Model Fit *				

Conditional Variance Dynamics				

GARCH Model	: sGARCH(1,1)			
Mean Model	: ARFIMA(0,0,0)			
Distribution	: std			
Optimal Parameters				

	Estimate	Std. Error	t value	Pr(> t)
mu	0.032636	0.005043	6.4710	0.000000
omega	0.007364	0.004348	1.6935	0.090357
alpha1	0.792934	0.401531	1.9748	0.048294
beta1	0.206066	0.190546	1.0815	0.279497
shape	2.288697	0.182745	12.5240	0.000000
Robust Standard Errors:				
	Estimate	Std. Error	t value	Pr(> t)
mu	0.032636	0.006359	5.13231	0.000000
omega	0.007364	0.004403	1.67251	0.094423
alpha1	0.792934	0.257047	3.08478	0.002037
beta1	0.206066	0.268430	0.76767	0.442682
shape	2.288697	0.126829	18.04551	0.000000
LogLikelihood : 120.4178				
Information Criteria				

Akaike	-1.9077			
Bayes	-1.7922			
Shibata	-1.9110			
Hannan-Quinn	-1.8608			

Weighted Ljung-Box Test on Standardized Residuals			

	statistic		p-value
Lag[1]	0.9248	0.3362	
Lag[2*(p+q)+(p+q)-1][2]	0.9963	0.4994	
Lag[4*(p+q)+(p+q)-1][5]	1.2193	0.8084	
d.o.f=0			
H0 : No serial correlation			
Weighted Ljung-Box Test on Standardized Squared Residuals			

	statistic		p-value
Lag[1]	0.01074	0.9175	
Lag[2*(p+q)+(p+q)-1][5]	1.04536	0.8493	
Lag[4*(p+q)+(p+q)-1][9]	2.03076	0.9013	
d.o.f=2			
Weighted ARCH LM Tests			

	Statistic	Shape	Scale P-Value
ARCH Lag[3]	0.1095	0.500	2.000 0.7407
ARCH Lag[5]	1.0368	1.440	1.667 0.7220
ARCH Lag[7]	1.4209	2.315	1.543 0.8371
Nyblom stability test			


Joint Statistic: 6.0655			
Individual Statistics:			
mu	0.02801		
omega	0.17617		
alpha1	0.50891		
beta1	0.09240		
shape	0.19085		
Asymptotic Critical Values (10% 5% 1%)			
Joint Statistic:		1.28	1.47 1.88
Individual Statistic:		0.35	0.47 0.75

Sign Bias Test			
	t-value	prob	sig
Sign Bias	1.6002	0.1123	
Negative Sign Bias	2.0275	0.0449	**
Positive Sign Bias	0.4809	0.6315	
Joint Effect	4.4082	0.2206	
Adjusted Pearson Goodness-of-Fit Test:			
group	statistic	p-value(g-1)	
1 20	93.71	7.251e-12	
2 30	115.28	3.065e-12	
3 40	121.98	1.780e-10	
4 50	131.48	1.799e-09	
Elapsed time : 0.08080196			

Tinjau hasil dari Gambar 13 dan Gambar 14 didapatkan beberapa temuan dari perbandingan kedua model. Berdasarkan Log-Likelihood dan Information Criteria, didapatkan model dengan distribusi t-Student memiliki Log-Likelihood lebih tinggi dan nilai AIC lebih rendah, yang mengindikasikan model ini lebih baik dalam menjelaskan data. Berdasarkan signifikansi parameter model, parameter α_1 dan β_1 dalam model GARCH (1,1) berdistribusi normal signifikan yang menunjukkan efek volatilitas masa lalu lebih kuat. Sedangkan pada model GARCH (1,1) t-Student didapat β_1 namun (*shape*) signifikan, mengakomodasi ekor distribusi yang lebih tebal. Serta berdasarkan uji ARCH LM residual kedua model tidak memiliki ARCH yang tersisa sehingga pada kedua model tersebut sudah baik dalam menangkap volatilitas dari data. Melalui beberapa temuan perbandingan dari kedua model, pada penelitian ini diputuskan untuk menggunakan model kedua yaitu GARCH(1,1) dengan distribusi t-Student.

HASIL DAN KESIMPULAN

Hasil Forecasting GARCH (1,1) dengan distribusi t-Student



Berdasarkan plot perbandingan antara volatilitas aktual dan prediksi model GARCH, dapat disimpulkan bahwa model GARCH secara umum mampu menangkap pola volatilitas jangka panjang, termasuk tren naik dan turun serta puncak volatilitas pada periode tertentu. Namun, model cenderung menghasilkan prediksi yang lebih halus dibandingkan dengan volatilitas aktual, sehingga kurang sensitif terhadap perubahan mendadak (*spike*) pada volatilitas. Selain itu, terdapat indikasi *overestimation* pada beberapa periode dengan volatilitas rendah dan *underestimation* pada periode dengan lonjakan volatilitas tajam. Hal ini menunjukkan bahwa model GARCH yang digunakan masih memiliki keterbatasan dalam menangkap dinamika volatilitas jangka pendek. Untuk meningkatkan kinerja model, diperlukan penyesuaian lebih lanjut, seperti eksplorasi distribusi residual alternatif, pemilihan model GARCH yang lebih kompleks (misalnya EGARCH atau TGARCH), serta optimasi parameter untuk menangani sifat volatilitas yang lebih dinamis.

Kesimpulan

Pada data penutupan saham PT Telkom Indonesia (Persero) Tbk (TLKM) dari Januari 2014 hingga Desember 2024 diperoleh data tidak memenuhi asumsi stasioneritas sehingga perlu dilakukan diferensial dengan *lag* 1. Data tersebut kemudian dibentuk menjadi model ARIMA (0,1,0) yang memenuhi asumsi *white noise*, berdistribusi normalitas, dan memiliki efek ARCH sehingga dapat dibentuk menjadi model GARCH. Dipilihlah model GARCH (1,1) yang merupakan model GARCH dengan orde paling sederhana yang kemudian menghasilkan model terbaik yaitu GARCH (1,1) dengan distribusi t-student. Berdasarkan persamaan model GARCH (1,1) berdistribusi t-student yang dibentuk berdasarkan *mean* model ARIMA (0,1,0) $Y_t - Y_{t-1} = 0.0326 + e_t$ didapatkan model GARCH(1,1) berbentuk $\sigma_{t|t-1}^2 = 0.007364 + 0.792934\sigma_{t-1|t-2}^2 + 0.206066r_{t-1}^2$ dengan residual e_t diasumsikan mengikuti distribusi t-student dengan parameter "shape" sebesar 2.288697, yang menunjukkan derajat kebebasan distribusi residual.

Melalui persamaan model GARCH (1,1) berdistribusi t-student tersebut didapatkan bahwa volatilitas jangka pendek (α_1) sebesar 0.792934 menunjukkan bahwa volatilitas sangat dipengaruhi oleh kejutan (*shock*) yang baru saja terjadi. Pengaruh volatilitas masa lalu terhadap volatilitas saat ini cukup kecil dibandingkan dengan kejutan baru yang ditunjukkan oleh persistensi volatilitas (β_1) sebesar 0.206066. Serta besaran kontribusi komponen konstan terhadap variansi bersyarat cukup rendah berdasarkan nilai ω yang kecil (0.007364).

REFERENSI

- Aklimawati, L., & Wahyudi, T. (2013). Estimating the Volatility of Cocoa Price Return with ARCH and GARCH Models. *Pelita Perkebunan (a Coffee and Cocoa Research Journal)*, 29(2).
- Cryer, J. D. (2008). *Time series analysis*. New York, NY: Springer.
- Ding, J. (2024). *Addressing the power of news in financial markets: Analysing stock returns with GARCH models* (Doctoral dissertation, Brunel University London).
- Jange, B. (2023). Prediksi volatilitas indeks harga saham gabungan menggunakan GARCH. *ARBITRASE Journal of Economics and Accounting*, 4(1), 1–6. <https://doi.org/10.47065/arbitrase.v4i1.1122>
- Marisetty, N. (2024). Prediction of Popular Global Stock Indexes Volatility by Using ARCH/GARCH Models. *GARCH Models*, 1–19. <http://dx.doi.org/10.2139/ssrn.4904475>
- Mustapa, F. H., & Ismail, M. T. (2019). Modelling and forecasting S&P 500 stock prices using hybrid Arima-Garch Model. *Journal of Physics Conference Series*, 1366(1), 012130. <https://doi.org/10.1088/1742-6596/1366/1/012130>
- Roszyk, N., & Ślepaczuk, R. (2024). The Hybrid Forecast of S&P 500 Volatility ensembled from VIX, GARCH and LSTM models. *arXiv preprint arXiv:2407.16780*.

LAMPIRAN

Codes

https://drive.google.com/drive/folders/1tIwVNNKFKKNY-rTuYAkq7rGO8s_4LG9T?usp=sharing